Лекция 4. Классификация и оценка качества моделей

Актуальность и область применения

Классификация представляет собой одну из фундаментальных задач машинного обучения с учителем, где главной целью является отнесение каждого объекта наблюдения к одной из заранее определённых категорий и классов [1]. В отличие от регрессии, где прогнозируется непрерывное значение, классификация работает с дискретными метками, что делает её применимой в огромном количестве практических сценариев – от фильтрации спама до медицинской диагностики и распознавания образов [4]. Процесс построения модели классификации – это не просто применение алгоритма к данным, а целостный, итеративный инженерный цикл, требующий внимания к каждому этапу [3].

Формальное определение

Строгое математическое определение задачи классификации начинается с описания пространства признаков X - множества всех возможных описаний объектов. Каждый объект представляется вектором признаков $x = [x_1, x_2, \dots, x_n]$, где n – размерность пространства признаков. Компоненты вектора отражают различные характеристики объекта, могут быть числовыми, категориальными или бинарными [2].

Множество меток классов Y – это конечное множество возможных категорий, к которым могут принадлежать объекты. В зависимости от задачи, это множество может иметь различную структуру. Для бинарной классификации такое множество содержит два элемента $Y = \{0,1\}, Y = \{\text{ложь}, \text{истина}\}$. Примеры такой классификации включают фильтрацию

спама (спам/не спам), медицинскую диагностику (болен/здоров) и тд. В многоклассовой задаче количество элементов превышает два $Y = \{C_1, C_2, \dots, C_k\}$, где $k > 2$, причем каждый объект принадлежит ровно одному классу. Примерами служат распознавание рукописных цифр, классификация видов растений. Особый случай представляет многометочная классификация, где один объект может одновременно принадлежать нескольким классам. Эта ситуация возникает при присвоении тегов статье, когда одна публикация может относиться к нескольким тематикам.

Классификатор можно представить в виде математической функции, цель которой состоит в нахождении отображения $f: X \to Y$, где для любого объекта $x \in X$ возвращается предсказанная метка класса $f(x) \in Y$. Это отображение называется классификатором или решающим правилом. Идеальный классификатор должен удовлетворять условию: $f(x) = y$ для всех $x \in X$, где y – истинная метка объекта x . Однако на практике такое отображение невозможно, потому что данные могут содержать шум и противоречия, описания объектов могут быть неполными или может присутствовать неопределенность в задаче. Поэтому цель формулируется как поиск такого f, которое максимизирует точность предсказаний на множестве объектов, представляющих практический интерес.

В случае обучения с учителем, имеется размеченная выборка $D = \{(x^i, y^i)\}$, где i = 1,2,…, m. Эта выборка представляет собой конечное множество пар «объект-метка», на основе которых обучается модель. Главная цель обучения заключается в построении модели, которая будет обобщать полученные знания на новые, не встречавшиеся ранее объекты.

Подготовка и корректное разделение данных

Качество моделей напрямую зависит от качества данных, на которых они обучаются. Подготовка данных является фундаментальным этапом, определяющим успех всего проекта. Этот этап включает очистку от дубликатов, обработку пропусков, преобразование признаков через кодирование и масштабирование, а также корректное разделение на обучающую, валидационную и тестовую выборки.

Первым шагом всегда является анализ распределения целевой переменной. Ситуация, когда один класс представлен значительно больше другого, представляет серьёзную проблему. Для борьбы с дисбалансом применяются различные стратегии, например, используются методы повторной выборки. Такие методы включают увеличение выборки миноритарного класса через дублирование или создание синтетических примеров (SMOTE), либо уменьшение выборки мажоритарного класса через случайное удаление объектов. С дисбалансом данных можно бороться на уровне алгоритмов, используя взвешивание классов, когда за ошибки на классах с низкой частотой встречаемости назначаются большие штрафы. Современные ансамблевые методы, такие как BalancedRandomForest, включают балансировку на уровне своей архитектуры.

В задачах классификации чаще всего встречаются количественные (числовые) и категориальные признаки. Работа с категориальными признаками требует особого внимания. Эти признаки, в свою очередь, делятся на номинальные (без естественного порядка, как цвет или город) и порядковые (с естественным порядком, как уровень образования или рейтинг). Алгоритмы машинного обучения работают только с числами. Чтобы преобразовать текстовые и символьные метки в числовой формат, используются специальные методы кодирования категориальных признаков. В качестве примеров таких методов можно выделить One-Hot Encoding, Label Encoding и Target Encoding. One-Hot Encoding преобразует каждую категорию в отдельный бинарный признак, что идеально подходит для

номинальных переменных, но может привести к проблемам высоких размерностей при большом количестве категорий. Label Encoding присваивает категориям числовые коды, но подходит только для порядковых признаков, так как для номинальных создаёт ложное отношение порядка. Target Encoding заменяет категорию средним значением целевой переменной для этой категории, создавая мощный, но склонный к переобучению признак.

Второй вид признаков – это количественный (числовой). Числовые признаки требуют масштабирования, особенно для алгоритмов, чувствительных к масштабам данных. Чтобы привести числовые признаки к единому масштабу, к исходным данным могут быть применены стандартизация (StandardScaler), нормализация (MinMaxScaler) или метод RobustScaler. Стандартизация преобразует данные к распределению с нулевым средним и единичной дисперсией, что оптимально для методов, предполагающих нормальность распределения. Нормализация сжимает данные в заданный диапазон, обычно [0, 1], но чувствительна к выбросам. RobustScaler использует медиану и межквартильный размах, демонстрируя устойчивость к аномальным значениям. Эти три метода не являются взаимозаменяемыми. Выбор метода зависит от статистических свойств исходных данных.

Многие алгоритмы машинного обучения при вычислении средних, расстояний и градиентов чувствительны к экстремальным значениям. Выбросы могут искажать работу моделей, особенно линейных. Их обнаружение осуществляется статистическими методами (правило 3σ, метод межквартильного размаха) или визуальными инструментами (box plots). В зависимости от природы выбросов и задачи, их либо удаляют, либо заменяют статистиками, либо преобразуют для уменьшения влияния.

При достаточном объеме данных для получения достоверной оценки обобщающей способности требуется разделение данных на три непересекающихся множества. Обучающая выборка (60-70% данных)

используется для непосредственного обучения модели. Валидационная выборка (15-20%) служит для подбора гиперпараметров и выбора между различными моделями. Тестовая выборка (15-20%) используется строго один раз для финальной оценки выбранной модели. Стратифицированное разделение сохраняет пропорции классов в каждой выборке, что важно при дисбалансе. Такое разделение обеспечивает метод train_test_split с параметром stratify, библиотека scikit-learn.

Чтобы объективно измерить, насколько хорошо обученная модель способна обобщать данные, используются различные методы оценки и валидации. Одним из таких методов является кросс-валидация. Кросс-валидация, особенно k-fold, предоставляет более надёжную оценку на небольших наборах данных. Данные разбиваются на k частей, модель обучается на k-1 частях и оценивается на оставшейся, процесс повторяется k раз с усреднением результатов. Такой подход применим для малого объема данных.

Линейные модели классификации

Линейные модели, несмотря на свою простоту, остаются мощным инструментом. В качестве примеров таких моделей можно выделить логистическую регрессию и метод опорных векторов.

Логистическая регрессия, является классическим алгоритмом бинарной классификации. Она вычисляет линейную комбинацию признаков ($z = w_0 + w_1x_1 + w_2x_2 + \cdots + w_nx_n$) , затем пропускает результат через сигмоидальную функцию, получая вероятность принадлежности к положительному классу. Каждый коэффициент w_i показывает направление и силу влияния соответствующего признака на предсказание. Чтобы избежать переобучения, добавляются штрафы за большие коэффициенты. Для этого используются

различные виды регуляризации, такие, как L1 (Lasso), L2 (Ridge) или их комбинации (ElasticNet).

Метод опорных векторов (SVM) предлагает геометрическую интерпретацию классификации: поиск разделяющей гиперплоскости с максимальным зазором между классами. Опорные векторы — объекты, лежащие на границе зазора — определяют положение гиперплоскости. Для нелинейно разделимых данных SVM использует ядра (kernel trick), которые неявно отображают данные в пространстве большой размерности, где они становятся линейно разделимыми. Выбор ядра (линейное, полиномиальное, радиальная базисная функция) зависит от структуры данных.

Нелинейные и ансамблевые подходы

Деревья решений представляют собой интуитивно понятные модели, которые рекурсивно разбивают данные на основе значений признаков. Каждый узел дерева задаёт вопрос о признаке, каждая ветвь представляет возможный ответ, а листья содержат метки классов. Критерии разделения — Джини, энтропия, прирост информации — оценивают качество разбиения. Преимущества деревьев включают простоту интерпретации, минимальные требования к подготовке данных и способность моделировать нелинейные зависимости. Однако они склонны к переобучению, нестабильны к малым изменениям данных и смещены в сторону признаков с большим количеством категорий.

Случайный лес преодолевает недостатки одиночных деревьев через ансамблирование. Идея бэггинга (Bootstrap Aggregating) предполагает создание множества бутстрэп-выборок, обучение отдельного дерева на каждой и агрегацию прогнозов через голосование. Двойная рандомизация — на уровне объектов (бутстрэп-выборки) и признаков (случайные подмножества для каждого разделения) — увеличивает разнообразие

деревьев и уменьшает корреляцию между ними. Random Forest оценивает важность признаков, либо через уменьшение критерия разделения, либо через уменьшение accuracy при перестановке значений признака. По сравнению с одиночными деревьями, случайный лес демонстрирует более высокую точность, меньшую склонность к переобучению и устойчивость к выбросам.

Градиентный бустинг реализует противоположную стратегию: последовательное построение ансамбля, где каждая следующая модель учится исправлять ошибки предыдущих. Алгоритм инициализируется простой моделью, затем итеративно вычисляет псевдо-остатки (градиенты функции потерь), обучает новую модель на этих остатках и добавляет её в ансамбль с коэффициентом обучения. Современные реализации — XGBoost, LightGBM, CatBoost — предлагают оптимизации скорости, памяти и обработки категориальных признаков. Градиентный бустинг часто достигает наилучшего качества, но требует тонкой настройки гиперпараметров и склонен к переобучению при неправильной настройке.

Оценка качества моделей

Оценка качества моделей классификации необходима, чтобы проанализировать способность модели обобщать данные и сделать осознанный выбор между разными моделями и их настройками. Фундаментальным инструментом для анализа работы бинарного классификатора является матрица ошибок, которая различает четыре типа исходов: истинно-положительные (TP), истинно-отрицательные (TN), ложно-положительные (FP) и ложно-отрицательные (FN). На основе матрицы ошибок вычисляются ключевые метрики качества.

Accuracy (доля верно определенных наблюдений) рассчитывается как (TP + TN)/(TP + TN + FP + FN), однако данная метрика может вводить в заблуждение при дисбалансе классов.

Precision (точность прогноза) определяется как TP/(TP + FP) и показывает долю верно предсказанных положительных объектов среди всех объектов, отнесенных моделью к положительному классу.

Recall (полнота) вычисляется как TP/(TP + FN) и отражает способность модели находить все положительные объекты.

Для сбалансированной оценки качества используется F1-score — гармоническое среднее precision и recall: 2 × (precision × recall)/(precision + recall).

Дополнительной метрикой, устойчивой к дисбалансу классов и не зависящей от выбора порога классификации, является ROC-AUC. ROC-кривая (Receiver Operating Characteristic) отображает зависимость True Positive Rate (чувствительности) от False Positive Rate (1 — специфичность) при варьировании порога бинарной классификации. AUC (Area Under Curve) представляет площадь под этой кривой и интерпретируется как вероятность того, что случайно выбранный положительный объект получит более высокую оценку вероятности принадлежности к классу, чем случайно выбранный отрицательный объект. Значение AUC = 0.5 соответствует случайному угадыванию, AUC = 1.0 — идеальному классификатору. ROC-AUC является одной из наиболее надежных метрик для сравнения моделей, поскольку оценивает качество ранжирования объектов в целом, а не только фиксированное бинарное предсказание.

Контрольные вопросы по лекции

1. Какие модели используются для задач классификации? В чём их ключевые отличия?
2. Что такое логистическая регрессия и как она работает?
3. Что такое деревья решений и какова их роль в машинном обучении?
4. Как оценить точность модели классификации и какие метрики для этого существуют?
5. Что такое ROC-кривая и ROC-AUC? Как интерпретировать значение AUC = 0.5 и AUC = 1.0?

Список источников:

1. Кугаевских, А. В. Классические методы машинного обучения : учебное пособие / А. В. Кугаевских, Д. И. Муромцев, О. В. Кирсанова. — Санкт-Петербург : Университет ИТМО, 2022. — 53 с.
2. Рашка, С. Машинное обучение с PyTorch и Scikit-Learn : книга / С. Рашка, Ю. Лю, В. Мирджалили. — Астана : Флориант, 2024. — 688 с.
3. Плас, Дж. Вандер. Python для сложных задач: наука о данных и машинное обучение. — Санкт-Петербург : Питер, 2022. — 576 с.
4. Грас, Дж. Data Science. Наука о данных с нуля. — Санкт-Петербург : БХВ-Петербург, 2021. — 336 с.